Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
(НИУ ИТМО)

АССИСТЕНТ СЕРВИСНОЙ СЛУЖБЫ НА ОСНОВЕ GRAPH RAG

ОТЧЁТ
ПО РЕЗУЛЬТАТАМ ИТОГОВОГО ПРОЕКТА
по дисциплине «ИИ-мышление: Наука и технологии»

Обучающиеся группы P1111
_____ Рязанов Антон
_____ Горохов Владимир Иванович
_____ Жилина Анжелика Дмитриевна
Дата 14.11.2026

Преподаватель
_____ Поляк Марк Дмитриевич
Оценка _____
Дата _____

Санкт-Петербург — 2026

Реферат

17 с., 1 рис., 4 табл., 5 источников.

ГРАФ ЗНАНИЙ, GRAPH RAG, ИЗВЛЕЧЕНИЕ ФАКТОВ, СЕРВИСНАЯ СЛУЖБА, ЯЗЫКОВАЯ МОДЕЛЬ, ERP

Объект разработки — ассистент диспетчера сервисной службы учебной компании «ПолярТех». Цель работы — связать сведения из технической документации с ценами и остатками из ERP, чтобы диспетчер мог определить актуальную деталь и подготовить заказ.

Из документов выделяются сущности и направленные связи. По графу выполняются поиск фактов и поиск по сводкам сообществ. Агент объединяет найденные факты с данными ERP и передаёт оформление заказа на подтверждение. Все 142 теста прошли. При сквозной проверке на тестовом индексе получены цена и остаток актуальной детали. Диагностический прогон на полном корпусе выявил пропуски связей при извлечении. Дополнительные сценарии обнаружили ошибки в источниках и обработке отказов.

Оглавление

Введение....4
1 ПОСТАНОВКА ЗАДАЧИ....5
2 РЕАЛИЗАЦИЯ АССИСТЕНТА....6
2.1 Извлечение и построение графа....6
2.2 Сообщества и режимы поиска....7
2.3 Агент и инструменты....7
3 РЕЗУЛЬТАТЫ ПРОВЕРОК....8
3.1 Проверки и сравнение режимов....8
3.2 Извлечение и индексация....9
4 СРАВНЕНИЕ РЕЖИМОВ....10
4.1 Подбор детали при ошибке E-17....10
4.2 Регламент устранения ошибки....10
5 АНАЛИЗ ОШИБОК....11
6 ГРАНИЦЫ СИСТЕМЫ....12
7 СЛЕДУЮЩИЙ ШАГ....13
8 ВКЛАД УЧАСТНИКОВ....14
9 ИСПОЛЬЗОВАНИЕ ИИ-ИНСТРУМЕНТОВ....15
Заключение....16
Список использованных источников....17

Введение

Код проекта доступен на GitHub [1].

Диспетчеру сервисной службы нужно сопоставить модель оборудования и код ошибки с отказавшим узлом, проверить актуальный артикул и узнать, где он есть в наличии. Руководства описывают исходную комплектацию, бюллетени — замены, регламенты — порядок ремонта, а отчёты о выездах — фактические отказы. Цена и остаток хранятся в системе учёта ресурсов предприятия (ERP) и запрашиваются во время ответа.

Цель работы — разработать ассистента, который отвечает по этому корпусу, показывает документы-источники и запрашивает подтверждение перед созданием заказа. Для сравнения используется плоский RAG. Он подбирает фрагменты по векторному сходству с вопросом. Graph RAG хранит связи между фактами и позволяет пройти от кода ошибки и модели к детали и её замене [2].

Мы проверили модули контрактными тестами, запустили сквозной сценарий с учебной ERP и сравнили четыре режима на одинаковых вопросах.

1 ПОСТАНОВКА ЗАДАЧИ

В учебной базе 80 документов. После разбиения по разделам образуются 92 чанка с идентификаторами, по которым можно восстановить документ и номер фрагмента. Эталон извлечения содержит 16 документов, а набор вопросов — 24 задания пяти типов. Он включает 5 локальных вопросов, 7 цепочек фактов, 4 обзорных вопроса, 5 запросов с инструментами и 3 вопроса с ожидаемым отказом [3].

Пример задачи диспетчера — подобрать деталь для ошибки E-17 на витрине AR-210. В руководстве ошибка связана с пусковым реле, а в комплектации указано реле P-1042. Сервисный бюллетень SB-2025-03 сообщает о замене на P-1042B. Если при поиске взять только руководство, ответ будет опираться на исходную комплектацию [1, 2].

Факты о наличии и цене запрашиваются по актуальному артикулу и складу. Результат поиска по документам нужен до запроса в ERP, поскольку вопрос может содержать только код ошибки и модель. Для заказа дополнительно требуется количество, указанное пользователем, и явное подтверждение.

2 РЕАЛИЗАЦИЯ АССИСТЕНТА

2.1 Извлечение и построение графа

Модуль extraction.py передаёт чанк языковой модели и запрашивает JSON со списками сущностей и связей. Семь типов сущностей и восемь допустимых направлений связей описаны в схеме. Коды приводятся к каноническому виду и сверяются с текстом чанка. Названия сверяются со словарём. Связь сохраняется, если подтверждены оба конца и их типы соответствуют схеме [3, 4].

При ошибке разбора JSON запрос повторяется с уточнением. Изменённый запрос получает отдельный ключ кеша. После второй ошибки возвращается пустой результат. Поле dropped содержит суммарное число отброшенных сущностей и связей.

Модуль graph_builder.py объединяет сущности по типу и имени. Источники узлов и рёбер хранятся как идентификаторы чанков, вес ребра равен числу уникальных чанков. При встречных заменах сохраняется направление с большим весом, при равенстве исключаются оба. Число таких конфликтов сохраняется в атрибутах графа.

Порядок обработки данных показан на рисунке 2.1. Граф и сводки собираются заранее. Агент обращается к готовому индексу и ERP во время ответа.



Рисунок 2.1 – Построение индекса и обработка вопроса

2.2 Сообщества и режимы поиска

Модуль communities.py переводит граф во взвешенный неориентированный вид для разбиения алгоритмом Лувена с фиксированным начальным значением генератора. Для каждой группы в модель передаются сущности, внутренние связи и их веса. Сводка ограничена 150 словами.

Локальный режим выделяет опорные коды и словарные названия. При одной опорной сущности поиск берёт окрестность на глубину до двух переходов. При нескольких он рассматривает пути длиной до трёх переходов и добавляет цепочки замен. Модель получает пронумерованные факты, а документы восстанавливаются по источникам рёбер.

Глобальный режим получает от модели оценку полезности каждой сводки и частичный ответ. Частичные ответы с положительной оценкой передаются в итоговый запрос. Плоский RAG выбирает до четырёх чанков по векторной близости к вопросу.

2.3 Агент и инструменты

У агента пять инструментов. Два вызывают локальный и глобальный поиск. Три обращаются к ERP за остатком, ценой и созданием заказа. Перед вызовом проверяются обязательные аргументы, формат артикула, название склада и количество. Артикул, появившийся только в аргументах модели, отклоняется. Агент просит сначала найти его в базе знаний.

Агент кеширует результаты одинаковых вызовов в рамках вопроса, ведёт журнал шагов и ограничивает их число. При временной недоступности ERP выполняется до трёх попыток. Перед выдачей ответа коды, цены и количества проверяются по вопросу и результатам вызовов.

3 РЕЗУЛЬТАТЫ ПРОВЕРОК

3.1 Проверки и сравнение режимов

Прошли 92 теста платформы и 50 контрактных тестов. Ruff завершился без замечаний. Ассистент и ERP вернули код 200 на /health. Сквозная проверка использовала FakeLLM, индекс из двух документов и учебную ERP.

В таблицах 3.1 и 3.2 приведён диагностический прогон на Qwen2.5 0.5B. Baseline использовал эту же модель для эмбеддингов.

Таблица 3.1 – Доля верных ответов по типам вопросов

Тип вопроса	**Baseline**	**Local**	**Global**	**Agent**
Локальный (5)	0,0 %	0,0 %	0,0 %	0,0 %
Цепочка фактов (7)	0,0 %	0,0 %	0,0 %	0,0 %
Обзорный (4)	0,0 %	0,0 %	25,0 %	0,0 %
Инструменты (5)	0,0 %	0,0 %	0,0 %	0,0 %
Отказ (3)	33,3 %	100,0 %	0,0 %	100,0 %
Итого (24)	4,2 %	12,5 %	4,2 %	12,5 %

Таблица 3.2 – Источники, выдуманные факты и стоимость ответов

Метрика	**Baseline**	**Local**	**Global**	**Agent**
Полнота источников	14,1 %	6,2 %	0,0 %	0,0 %
Ответы с выдуманными фактами	12,5 %	0,0 %	16,7 %	0,0 %
Вызовы модели на вопрос	1	0,04	59	2,29
Токены на вопрос	1 140,92	9,25	24 541	1 564,08

Полнота источников учитывает группы документов. Выдуманные факты — неподтверждённые коды, цены и остатки. В стоимость входят вызовы из кеша [5].

3.2 Извлечение и индексация

Конфигурация прогона — Qwen2.5 0.5B, та же модель для эмбеддингов в baseline. Точность измеряет долю допустимых извлечённых фактов, полнота — долю обязательных фактов из эталона, которые удалось извлечь. Для связей к допустимым относятся и необязательные факты из разметки [5].

Таблица 3.3 – Извлечение на 16 эталонных документах

Объекты извлечения	**Точность**	**Полнота**	**Найдено**	**В эталоне**
Сущности	80,6 %	45,5 %	93	165
Связи	100,0 %	0,6 %	1	161

Таблица 3.4 – Полный индекс и стоимость построения

Показатель	**Значение**
Чанки	92
Узлы графа	64
Рёбра графа	6
Сообщества	58
Конфликты замен	0
Отброшенные сущности и связи	386
Вызовы модели	150
Входные токены	84 680
Выходные токены	45 011

На эталонной выборке проверки отбросили 106 записей, из них 76 связей. На полном корпусе отброшено 277 связей. Разбивка получена повторным выполнением проверок над сохранёнными ответами модели.

На Qwen2.5 единственная извлечённая связь на эталоне оказалась корректной. При полноте 0,6 % в графе отсутствует большая часть обязательных связей.

4 СРАВНЕНИЕ РЕЖИМОВ

4.1 Подбор детали при ошибке E-17

Чтобы получить P-1042B, нужно связать ошибку с пусковым реле, найти P-1042 в комплектации AR-210 и пройти ребро замены из бюллетеня SB-2025-03. Руководство указывает исходную деталь P-1042 [1, 2]. При проверке на тестовом индексе цепочка привела к P-1042B, а агент запросил её наличие и цену. ERP вернула 3 штуки на складе в Казани и цену 2630 руб.

На полном корпусе диагностическая модель не извлекла ни одного из четырёх рёбер этой цепочки. Локальный поиск вернул «в базе знаний не найдено». Этот результат показывает зависимость поиска от полноты индекса даже при корректной обработке готовой цепочки.

Диагностический baseline ответил про замену P-2054B на P-2054C. Поиск подал бюллетень о другой детали, а руководство AR-210 и нужный бюллетень отсутствовали в подборке.

4.2 Регламент устранения ошибки

Ответ на вопрос «По какому регламенту устраняют ошибку E-17?» содержится непосредственно в документе SP-104. Плоскому RAG достаточно найти этот фрагмент. Локальному Graph RAG требуется извлечённое ребро FIXED_BY от E-17 к SP-104. Если ребро потеряно при построении индекса, текст регламента остаётся доступен плоскому поиску, а граф теряет прямой путь к ответу [2, 3].

В этом прогоне baseline выбрал четыре отчёта о выездах и ответил про E-14. Локальный режим вернул отказ. Оба ответа оценщик отклонил.

5 АНАЛИЗ ОШИБОК

Извлечение. На Qwen2.5 0.5B 160 из 161 обязательной связи не были найдены. Например, в бюллетене SB-2025-03 модель пометила P-1042 как ProductLine. Проверка отклонила эту сущность и связь с поставщиком, поскольку код детали был указан с типом линейки. В полном диагностическом графе отсутствовало и ребро замены на P-1042B.

Поиск по сводкам. В воспроизводимом тесте глобальный режим ответил «Отказало пусковое реле», но вернул пустое поле sources при наличии документа в исходном графе. Поиск теряет сведения о сообществе, когда записывает только текст частичного ответа. Итоговая ветка всегда устанавливает refused=False, даже если модель прямо сообщает, что данных нет.

Вызов инструмента и генерация. В диагностическом запросе к агенту модель вызвала get_price с кодом модели AR-210 вместо артикула и добавила лишний аргумент warehouse. Проверка аргументов отклонила вызов до обращения к ERP. После этого агент написал, что детали нет на складе, хотя запроса остатков не было. Отдельный тест с FakeLLM показал, что при отсутствии наблюдений возможен неподтверждённый текст с refused=True.

6 ГРАНИЦЫ СИСТЕМЫ

Агент может читать технические документы и запрашивать цену и остаток детали. Создание заказа выполняется отдельным инструментом create_service_order. Перед вызовом проверяются артикул, склад, положительное целое количество и совпадение количества с запросом.

При confirm=False агент возвращает needs_confirmation=True и pending_action с аргументами заказа. Инструмент вызывается после явного подтверждения при confirm=True. Сквозная проверка прошла на отдельном экземпляре учебной ERP. Запрос без подтверждения вернул данные предстоящего действия, а подтверждённый запрос создал заказ SO-000001.

Неизвестный ERP артикул приводит к ответу об отсутствии данных. Остаток 0 возвращается как значение для существующей детали. При временной недоступности ERP агент повторяет вызов. Найденные отклонения в тексте отказов и источниках описаны в разделе 5.

7 СЛЕДУЮЩИЙ ШАГ

Добавить проверку FR-10 для глобального режима с двумя сводками и разными источниками. При положительной оценке сводки сохранять идентификатор сообщества вместе с частичным ответом. Для выбранных сообществ собрать документы по источникам внутренних рёбер, на которых построены сводки, и убрать повторы.

При полезной сводке о пусковом реле ответ должен содержать документ из графа. Проверка должна также отвергнуть источник сводки с нулевой оценкой и подтвердить, что итоговый отказ возвращается с refused=True. После изменения полноту источников можно измерить на тех же вопросах и модели.

8 ВКЛАД УЧАСТНИКОВ

Рязанов Антон отвечал за извлечение фактов и построение графа (extraction.py, graph_builder.py), общую проверку и описание результатов извлечения и индексации.

Горохов Владимир Иванович реализовал инструменты, работу с ERP и цикл агента (tools.py, agent.py).

Жилина Анжелика Дмитриевна реализовала разбиение графа на сообщества, создание сводок, а также локальный и глобальный поиск (communities.py, search.py).

9 ИСПОЛЬЗОВАНИЕ ИИ-ИНСТРУМЕНТОВ

OpenAI Codex использовали при планировании, разработке модулей извлечения и сборки графа, проверке проекта и подготовке отчёта.

Ассистент обращается к локальной языковой модели через Ollama, чтобы извлекать факты, составлять сводки, формировать ответы и выбирать инструменты. Для проверки сценария подтверждения заказа мы задали последовательность ответов через FakeLLM.

Заключение

Команда реализовала шесть модулей. На тестовом индексе подтверждена цепочка от подбора актуальной детали до запроса к ERP и передачи заказа на подтверждение. Результаты тестов подтверждают согласованность основных интерфейсов.

Дополнительные проверки выявили потерю источников в глобальном режиме и несогласованные отказы в глобальном режиме и у агента. Диагностический эксперимент также показал, что полнота извлечения прямо влияет на возможность ответить даже при корректном обходе графа.

На вопросах с ожидаемым отказом локальный режим и агент получили по три верных ответа. Для выводов о качестве ответов в штатной конфигурации требуется прогон с Qwen3 4B Instruct и bge-m3.

Список использованных источников

1. Ассистент сервисной службы на Graph RAG. Репозиторий команды [Электронный ресурс]. https://github.com/antoniocra04/llm-project (дата обращения 14.11.2026).

2. Графы знаний и Graph RAG. Теория проекта [Электронный ресурс]. https://github.com/antoniocra04/llm-project/blob/ac991c3/docs/theory.md (дата обращения 14.11.2026).

3. Корпус и схема графа знаний. Описание данных [Электронный ресурс]. https://github.com/antoniocra04/llm-project/blob/ac991c3/docs/data.md (дата обращения 14.11.2026).

4. Функциональные требования к ассистенту [Электронный ресурс]. https://github.com/antoniocra04/llm-project/blob/ac991c3/docs/requirements.md (дата обращения 14.11.2026).

5. Оценка качества ответов и извлечения [Электронный ресурс]. https://github.com/antoniocra04/llm-project/blob/ac991c3/docs/evaluation.md (дата обращения 14.11.2026).